

基于 VTP 特征提取的 PSPNet 语义 分割实现

学 号 U202314606
姓 名 吴可非

目录

1	核心模型原理综述	3
1.1	VTP: 基于生成式预训练的视觉表征与分词模型	3
1.2	PSPNet: 金字塔池化多尺度聚合网络	3
2	图像语义分割算法实现	4
2.1	整体架构逻辑	4
2.2	数据集构建与数据预处理	4
2.3	训练策略与参数设置	5
3	实验结果	5
3.1	特征提取有效性验证 (PCA 可视化)	5
3.2	图像语义分割结果分析	6
3.3	定量评价与对比分析	8
3.4	轻量化主干网络 (VTP-Small) 的性能测试	9
3.5	基于 DenseCRF 的推理预测后处理	11
4	总结	13
	参考文献	13
	附录	14

1 核心模型原理综述

1.1 VTP: 基于生成式预训练的视觉表征与分词模型

VTP (Visual Tokenizer Pre-training) [1]是一种旨在解决视觉分词器“预训练扩展问题(pre-training scaling problem)”的统一预训练框架。传统的视觉分词器往往采用纯像素重建作为训练目标,这导致其潜空间过度偏向低级物理信息,而缺乏高级语义表征能力,因此,单纯增加计算量往往无法带来生成质量的提升,甚至会导致性能退化。

而 VTP 的创新之处在于将 CLIP、SSL 目标与像素重建损失函数进行联合优化,即利用 L_{CLIP} 注入全文语义的理解,利用 L_{SSL} 让模型关注局部纹理的同时,也能同时学习图像的全局结构和空间语义,利用 L_{REC} 保证纹理细节。同时 VTP 是完全基于 Vision Transformer 构建,相比于传统的 CNN 架构,ViT 架构不仅在表征学习上展现出了更好的灵活性,还具备更强的全局感受野和长程依赖建模能力。更重要的是,VTP 揭示了一条全新的视觉分词器扩展规律 (Scaling Law):即“语义理解是驱动生成能力的关键(Understanding is a key driver of generation)”。

1.2 PSPNet: 金字塔池化多尺度聚合网络

PSPNet (Pyramid Scene Parsing Network) [2]是语义分割领域的经典架构,其核心贡献在于提出了 PPM (Pyramid Pooling Module)模块,该模块通过以下两个关键机制显著提升了模型对场景的理解能力:

全局上下文聚合:针对像素级分类中容易出现的局部歧义问题,PPM 通过 1×1 、 2×2 、 3×3 和 6×6 四个不同尺度的池化操作,有效的捕捉图像的全局背景信息,缓解语义混淆。

多尺度特征融合:将不同尺度的池化特征进行降维和上采样,最后与原始特征图拼接,使模型同时具备微观细节和宏观语义的感知能力,输出更为准确的分割结果。

2 图像语义分割算法实现

该算法将 VTP 对高频细节与全局语义的联合捕获能力与 PSPNet 的空间聚合能力相结合，构建了有效的图像语义分割算法。

2.1 整体架构逻辑

该算法的整体流程如下：




图 1：算法架构示意图

为了使 Vision Transformer 的特征能够适配下游的 PSPNet 并最大化利用 VTP 对空间细节的保留能力，本算法对特征提取机制进行了优化。考虑到传统的 ViT 架构通常只利用单一的顶层输出，容易导致细粒度空间信息的流失，本算法通过调用 `get_intermediate_layers_feature` 接口，直接提取了主干网络最后四层的中间层特征。VTP 的特征提取模块在底层具有二维的空间拓扑结构，直接输出了空间对齐的二维特征图，从而免去了繁琐的一维序列重构操作。随后，算法对这四层特征进行融合，构建出一个兼具高层全局语义与底层高频细节的聚合特征表示。该聚合特征作为基础特征图送入 PSPNet，与经过 PPM 模块提取到的深层全局上下文先验进行拼接。最终，叠加后的高维度特征通过分类头的多层卷积映射，被精确还原并上采样为 512×512 尺寸的分割掩码。

2.2 数据集构建与数据预处理

该图像语义分割算法采用 Pascal VOC 2012 语义分割数据集[3]进行模型的训练与验证，数据集的构建逻辑通过自定义的 `Dataset` 类实现。算法读取 `ImageSets` 目录下的分割任务划分文件 (`train.txt` 与 `val.txt`)，获取对应的样本名称索引，进而精确匹配 `JPEGImages` 文件夹中的原始 RGB 图像与 `SegmentationClass`

文件夹下的像素级标签掩码。

在图像输入预处理环节，为了最大化捕获空间细节，所有输入图像均被统一缩放至 512×512 的高分辨率。随后，图像转换为 Tensor 并运用 ImageNet 标准分布参数进行归一化。对于标签掩码则是采用了与原图不同的最近邻插值方式，这种方式避免了插值计算产生非整数的过渡值，从而绝对保证了掩码矩阵中的每一个像素依然代表着离散类别标签。

2.3 训练策略与参数设置

由于 VTP 模型已经展现出了极强的零样本泛化能力与高度线性可分的特征潜空间。尽管其核心设计包含了生成式分词器的目标，但其提取的高维特征已具备极其丰富的全局结构与高阶语义。因此本次实验采用了现代视觉大模型极其经典的“冻结特征底座 + 轻量化任务头”训练方式，总训练周期为 60 个 epoch。

在整个训练周期内，VTP 主干网络的所有参数被完全冻结，梯度更新仅作用于随机初始化的特征适配器 PPM 模块以及最终的分类头。采用完全冻结策略出于两点核心考量：首先，VTP-Large 拥有庞大的参数量，在下游相对较小的分割数据集上直接微调极易导致严重的反向拟合与灾难性遗忘，破坏其原本优秀的预训练表征；其次，冻结主干网络降低了显存开销，使得模型能够在有限的算力下，支持接收较高分辨率的图像输入，从而最大限度地保留微小目标的物理边缘细节。由于模型参数量较大，实际训练的 Batch Size 设置为较小的值，并配合余弦退火学习率调度器以及梯度累计的方式，确保了特征投影层与分类头在庞大且固定的高维特征空间中平稳进行训练。

在损失函数的设计上，由于 VTP 提供的特征本身已经具备极高的类间区分度，因此在全部 60 个 epoch 中，本实验全程采用稳定的 CE-Dice 联合损失函数。其中，CE Loss 负责像素级别的多分类准确性，而 Dice Loss 则专门针对前景物体进行形状和边界的连贯性优化，这两者的结合实现了较好的语义分割效果。

3 实验结果

3.1 特征提取有效性验证（PCA 可视化）

为了直观验证 VTP 的特征表征特性，本实验在训练初期提取了骨干网络融

合后的高维特征张量，并利用主成分分析（PCA）将其提取前三个主成分，降维映射至 RGB 空间进行可视化分析。




图 2：VTP Backbone 特征 PCA 可视化

如图 2 所示，与纯判别式模型（如 DINOv3）那种将前景与背景清晰剥离的现象不同，VTP 的特征图呈现出截然不同的视觉分布。在 2048×2048 的高分辨率输入下，即使尚未进行任何特定任务的微调，VTP 依然展现出了极其敏锐的高频细节保留与空间感知能力。

特征图中不仅勾勒出了物体的宏观轮廓，同时也还原了局部的纹理、光影变化以及微小的几何结构等。这种现象印证了 VTP 的生成式预训练的方式，对于下游的密集预测任务而言，它完整保留了原图的二维空间拓扑结构，为下游 PSPNet 在处理复杂遮挡和小目标时提供了信息量极其丰富的特征。

3.2 图像语义分割结果分析

在从上游获取 VTP 输出的特征后，通过 PPM 模块的全局上下文聚合与分类头的映射，模型输出了最终的语义分割结果。




图 3：不同语义分割算法的可视化对比

为了直观验证本算法的分割性能，图 3 展示了在多种场景下，VTP+PSPNet 模型与其他的经典模型（FCN、DeepLab）的可视化对比结果。

观察图 3 可知，在处理受复杂光影、局部纹理突变或严重遮挡干扰的区域时，传统基于 CNN 的模型（如 FCN 与 DeepLab）往往容易陷入局部最优，从而在目标主体内部产生类别误判与语义碎片化的空洞。相比之下，本文模型展现出了更好的鲁棒性。它不仅能够克服目标内部由于高频反光或阴影带来的特征干扰，维持高度的内部语义连贯性，更能在面对含有微小镂空或纤细几何特征的复杂结构时，精准地剥离背景并刻画极其细致的物理边界，有效避免了将复杂结构预测为模糊大色块的现象。

这种在宏观语义定位上的优异表现，根本上得益于 VTP 大模型独特的生成

式预训练范式。通过联合优化对比学习（CLIP）与自监督目标（SSL），即便在完全冻结主干网络的前提下，模型依然能为下游 PSPNet 提供饱满的语义特征底座，从而在整体 mIoU 等基于面积度量的数学指标上取得了突出的成绩。然而，不可忽视的是，生成式 ViT 架构在应用于像素级密集预测任务时也暴露出了一定的固有劣势。与自带空间平滑与局部连贯性偏置的纯判别式 CNN 模型不同，基于离散 Patch 建模的 VTP 在缺乏特定下游微调时，各区域特征呈现出较强的独立性。加之解码阶段直接进行大倍率上采样，导致输出掩码图的物理边缘往往呈现出模糊与锯齿状。因此，虽然其全局上下文感知能力极强，但在视觉感知的边缘精细度上仍有欠缺，这也为后续通过进行局部解冻微调的实验指明了方向。

3.3 定量评价与对比分析

为了客观的评估模型的语义分割的性能，本节在 Pascal VOC 2012 验证集上进行了定量的评估，其中评估的指标使用平均交并比（Mean Intersection over Union, mIoU）与像素准确率（Pixel Accuracy, PA）。

模型架构	aero	bike	bird	bus	car	chair	table	dog	person	sheep	sofa	train	mIoU
FCN [4]	76.8	34.2	68.9	75.3	74.7	21.4	46.8	71.8	73.9	72.4	37.4	70.9	62.2
DeepLab [5]	84.4	54.5	81.5	85.1	79.1	30.7	59.8	79.0	80.8	82.2	50.4	73.1	71.6
DPN [6]	87.7	59.4	78.4	89.3	83.5	31.7	62.6	81.9	82.3	83.2	53.4	77.9	74.1
PSPNet [2]	91.8	71.9	94.7	95.2	89.9	39.3	71.7	90.5	89.6	89.6	64.0	85.1	82.6
Dinov3+PSPNet	96.8	76.6	92.8	95.4	92.7	51.0	67.5	93.0	92.8	83.5	60.8	91.5	84.2
VTP+PSPNet	86.8	56.8	90.6	92.6	81.6	53.8	64.0	91.6	86.9	89.9	66.4	90.3	80.7

表 1：不同语义分割方法在 PASCAL VOC 2012 数据集上的 Per-class mIoU 对比（注：为适应页面排版，本表仅展示了 12 个具有代表性的类别 IoU，最右侧的总体 mIoU 为包含背景在内的 21 个类别的平均值。表中前四项经典方法的数据引自 PSPNet 原始文献在 VOC 2012 测试集上的评估结果；Dinov3+PSPNet 和 VTP+PSPNet 项为该算法在 VOC 2012 验证集上的评估结果）

如表 1 所示，本算法在 PASCAL VOC 2012 验证集上取得了较好的结果，总体 mIoU 达到了 80.7%。通过横向对比可知，即使在完全冻结主干网络且未进行复杂数据增强的情况下，本算法依然超越了 FCN（62.2%）、DeepLab（71.6%）以及 DPN（74.1%）等经典 CNN 架构，这充分证明了 VTP 大模型强大的生成式

语义表征潜力。

对各前景物体的 **Per-class IoU** 进行分析可以进一步发现该模型在语义分割任务上的特点：首先，模型在特征鲜明、轮廓完整的目标上表现出了较好的水准，例如飞机（86.8%）、鸟（90.6%）、公交车（92.6%）和火车（90.3%）等类别均取得了较好的成绩。其次，对于室内场景中的家具物品，由于通常伴随严重的相互遮挡或复杂的背景干扰，导致特征提取极其困难，各模型的绝对性能在该类场景下均有所下降。然而值得关注的是，本文构建的 **VTP+PSPNet** 在这些困难类别上展现出了远超传统模型的鲁棒性。例如在结构复杂且多镂空的“chair”和“sofa”类别上，本算法分别取得了 53.8% 和 66.4% 的成绩，超越了的标准 **PSPNet** 以及 **Dinov3+PSPNet** 基准。

这一现象说明了 **VTP** 独特的联合优化预训练模式的作用，其特征潜空间能够更好地保留被遮挡物体的局部纹理与空间高频信息，有效克服了传统 **CNN** 在经过多次降采样后容易丢失关键边缘细节的缺陷。综合来看，尽管本模型在整体 **mIoU** 上与全量微调的基线 **PSPNet** (82.6%) 存在差距，但考虑到这是在冻结 **VTP-Large** 主干参数的条件下取得的成果，本文架构在细粒度特征保留与复杂重叠场景解析上已展现出了优势与更好的优化空间。

3.4 轻量化主干网络（VTP-Small）的性能测试

继前文基于 **VTP-Large** 架构的实验之后，为进一步验证 **VTP** 模型在不同参数量级时的表现，本节设计并训练了以 **VTP-Small** 为主干网络的轻量化分割模型。在微调策略的制定上，考虑到轻量级模型的参数容量有限，此次实验中本节实施了两项较为激进的策略调整：一是将主干网络的最后 8 层进行解冻；二是将输入图像的训练与推理分辨率提升至 1024×1024 。




图 4: 不同 Backbone 性能的可视化对比

在定性的视觉评估中，得益于 1024×1024 分辨率带来的 4 倍像素密度增益以及解冻了 Backbone 部分参数进行训练，VTP-Small 展现出了相对更好边缘感知力，如图 4 所示，VTP-Small 生成的分割掩码在物理边界的贴合度与锐利度上，甚至在视觉观感上优于 VTP-Large 的 Baseline 模型。

主干网络	mIoU	PA
VTP-Small	74.7	94.3
VTP-Large	80.7	95.7

表 2: 不同 Backbone 在 PASCAL VOC 2012 验证集上的性能对比

然而如表 2 所示，VTP-Small 模型在验证集上的 mIoU 指标仅为 74.7%。深入分析认为，这种视觉边缘较好但全局指标受挫的反差，本质上是模型参数量以及空间分辨率的共同影响所导致的。一方面，高分辨率配合深层微调，成功激发了模型对高频物理边界的精确描绘能力；但另一方面，VTP-Small 由于参数容量与网络深度的缩减，其绝对感受野相对有限，当面对 1024×1024 的大尺寸输入时，模型难以有效捕获全局上下文信息，从而拉低了整体的 mIoU 分数。

综合上述轻量化实验的性能折损，以及大模型深度微调带来的指标背离风险，本文得出了一个明确的结论：单纯依赖模型架构的缩放或训练策略的激进调整，难以同时兼顾高水平的分类精度（mIoU）与精确的物理边界（视觉效果）。基于这一痛点，本文在下一节中转变优化思路，尝试使用在不改变 VTP-Large 最佳微调权重的前提下，引入即插即用的 DenseCRF（全连接条件随机场）后处理机制，以零训练成本实现精度与视觉质量的解耦与提升。

3.5 基于 DenseCRF 的推理预测后处理

通过实验对比发现，尽管 VTP 模型在 mIoU 指标上达到了较高水平，但在预测掩码的视觉呈现上，其边界解析度与基于判别式预训练的 Vision Transformer 模型（如 DINO 系列）存在一定差异，而这种差异主要源于预训练方式的不同。针对这个问题，本节在推理阶段尝试引入了 DenseCRF（全连接条件随机场）进行后处理来实现对边界的优化。DenseCRF 通过建立像素级的一元势能与二元势能之间的概率模型，将模糊的预测边界重新映射到原图的高频能量边缘上，从而使模型在保持 mIoU 的同时获得了更符合视觉感知的精确边界。




图 5：后处理可视化对比图

通过对图 5 中各模型输出结果的对比分析可以看出 DenseCRF 后处理机制在提升语义分割边界质量方面具有显著作用。而且这种优化策略有效地利用了原图的空间色彩先验，在不改变模型核心参数的情况下抑制了局部分类噪声，实现了更好的语义连贯性与边缘锐利度之间的平衡，为获得符合视觉一致性的分割掩码提供了低成本且高效的优化方案。

4 总结

在尝试实现了 Dinov3-PSPNet 结构之后本实验尝试实现了基于生成式视觉分词大模型 VTP 与 PSPNet 的联合架构。

在具体的模型调试与训练阶段，针对 PASCAL VOC 2012 数据集中前景与背景像素严重失衡的问题，本实验选用了具备较强鲁棒性的 CE-Dice 联合损失函数。同时，考虑到 VTP 作为生成式大模型在小规模判别式数据集上容易过拟合以及灾难性遗忘，本实验采取了“冻结特征底座+轻量化任务头”与局部深层解冻相结合的谨慎微调策略，保障了模型在庞大高维特征空间中的稳定收敛。

除此之外，针对生成式 ViT 架构在像素级密集预测中固有的物理边缘模糊问题，本文开展了深入的消融与探索。通过构建 VTP-Small 的高分辨率(1024×1024)微调实验，结合实验结果分析了模型绝对感受野与空间分辨率之间的关联，同时在实验过程中也遇到了“视觉边界锐利度”与“全局分类精度(mIoU)”之间的指标背离现象。基于这一情况，本实验后续主动引入了 DenseCRF 作为推理后处理机制，在零额外训练成本的前提下，巧妙利用原图的空间色彩先验抑制了局部分类噪声。

最终实验结果表明，在 PASCAL VOC 2012 验证集上，本文构建的 VTP - PSPNet 模型取得了 80.7%的平均交并比(mIoU)，显著超越了 FCN、DeepLab 等经典 CNN 基准。同时，通过 PCA 特征可视化与轻量化主干网络消融对比，不仅验证了 VTP 在联合优化预训练下卓越的高阶语义与高频细节保留能力，也证实了 DenseCRF 在解耦并双向提升语义精度与视觉边界质量上的有效性。

参考文献

- [1] YAO J, SONG Y, ZHOU Y, et al. Towards Scalable Pre-training of Visual Tokenizers for Generation[J]. arXiv preprint arXiv:2512.13687, 2025.
- [2] Zhao H, Shi J, Qi X, et al. Pyramid scene parsing network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2881-2890.
- [3] Everingham M, Van Gool L, Williams C K I, et al. The pascal visual object classes (voc) challenge[J]. International journal of computer vision, 2010, 88(2): 303-338.

- [4] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 3431-3440.
- [5] Chen L C, Papandreou G, Kokkinos I, et al. Semantic image segmentation with deep convolutional nets and fully connected crfs[C]//International Conference on Learning Representations (ICLR). 2015.
- [6] Liu Z, Li X, Luo P, et al. Semantic image segmentation via deep parsing network[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1377-1385.

附录

项目源码: <https://github.com/691292605/VTP-PSPNet>